Modelado predictivo del tráfico e ingresos en peajes colombianos mediante Machine Learning

Bamsi Mendez Posada

Ciencias de la Computación

Universidad Nacional de Colombia, Sede Manizales

bamendezp@unal.edu.co

Workshop Nuevas Tendencias en Estadística

UNIVERSIDAD NACIONAL DE COLOMBIA

Resumen

Este trabajo presenta un pipeline de modelado predictivo aplicado a datos reales de peajes en Colombia, con el objetivo de estimar el **Tráfico Promedio Diario** y el **Ingreso Promedio Diario**. Se comparan modelos de regresión tradicionales (Lineal, Random Forest, XGBoost, SVR) y redes neuronales (ANN/MLP), tanto en predicción directa como en esquema de **predicción en cascada**, donde la estimación de ingresos depende de la predicción previa de tráfico. Los resultados muestran que los modelos de árbol superan a las redes neuronales en robustez, interpretabilidad y desempeño, especialmente en la fase de predicción de ingresos.

Objetivos

- Desarrollar un pipeline de aprendizaje automático para predecir el tráfico e ingresos en peajes colombianos.
- Comparar el desempeño de modelos de regresión tradicionales (aprendizaje supervisado) y redes neuronales (aprendizaje profundo), tanto en predicción directa como en cascada.
- Evaluar la utilidad del esquema de cascada para estimar ingresos a partir de predicciones de tráfico.

Metodología

- **Datos:** Registros confiables de peajes (fuente pública *Kaggle*) con variables de tráfico, ingresos, tarifas, tipo de vehículo y localización.
- **Preprocesamiento:** Limpieza, codificación categórica, escalado, generación de variables derivadas y control de nulos.
- **Modelos:** Regresión Lineal, Random Forest, XGBoost, SVR y redes neuronales MLP.
- **Evaluación:** Métricas de regresión (RMSE, MAE, R^2), validación cruzada y análisis gráfico de valores predichos vs reales.
- **Cascada:** La predicción de tráfico se usa como entrada para estimar los ingresos, replicando un flujo real de toma de decisiones.

Análisis Exploratorio (EDA)

Se realiza un análisis descriptivo y visual para comprender la estructura del conjunto de datos:

- Distribuciones de tráfico e ingresos por tipo de vehículo y peaje.
- Relación entre tarifas y tráfico.
- Correlaciones entre variables numéricas.
- Series de tiempo mensuales y mapas geográficos de tráfico total.

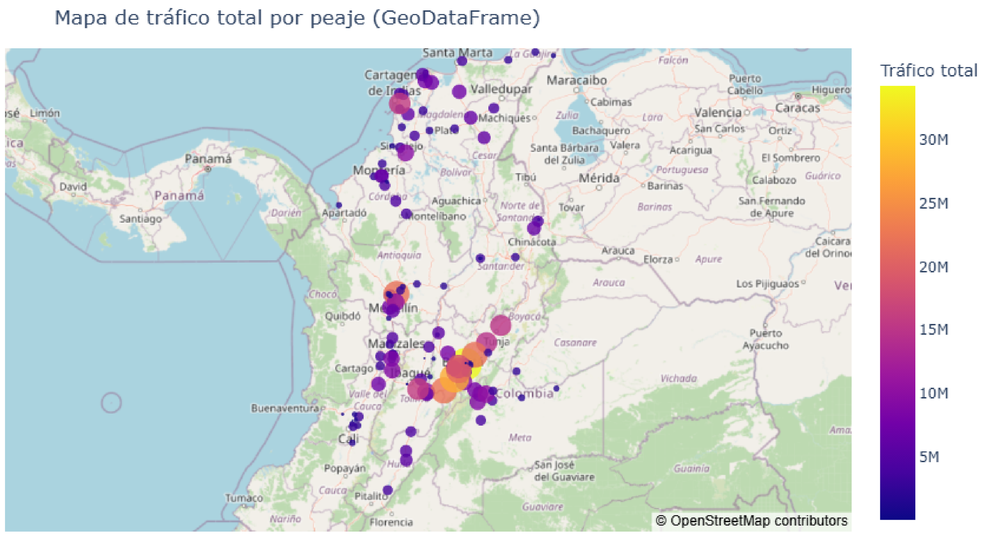


Figura 1:Distribución de tráfico e ingresos por tipo de vehículo

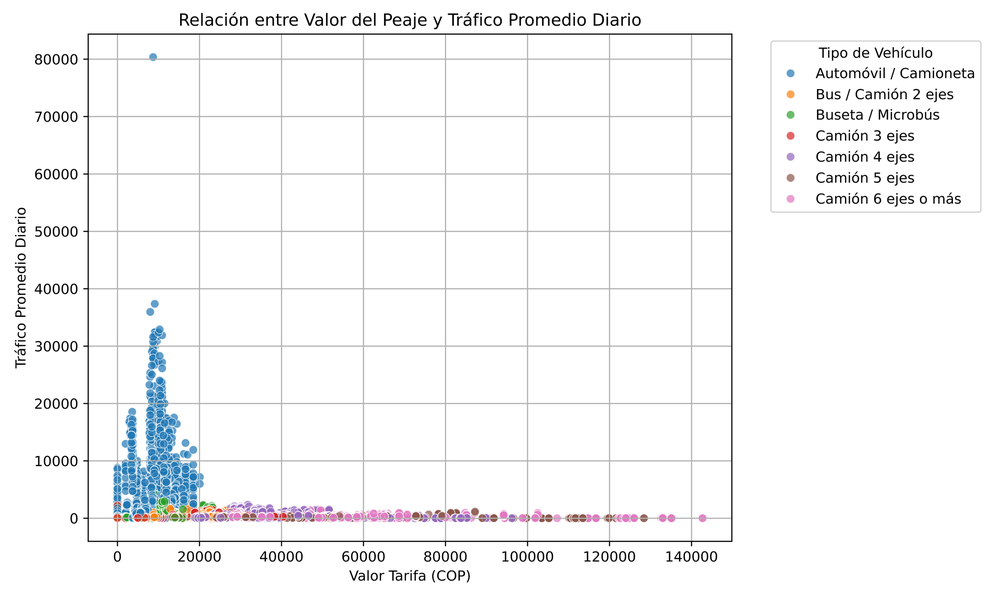


Figura 2:Relación entre tarifa y tráfico promedio diario

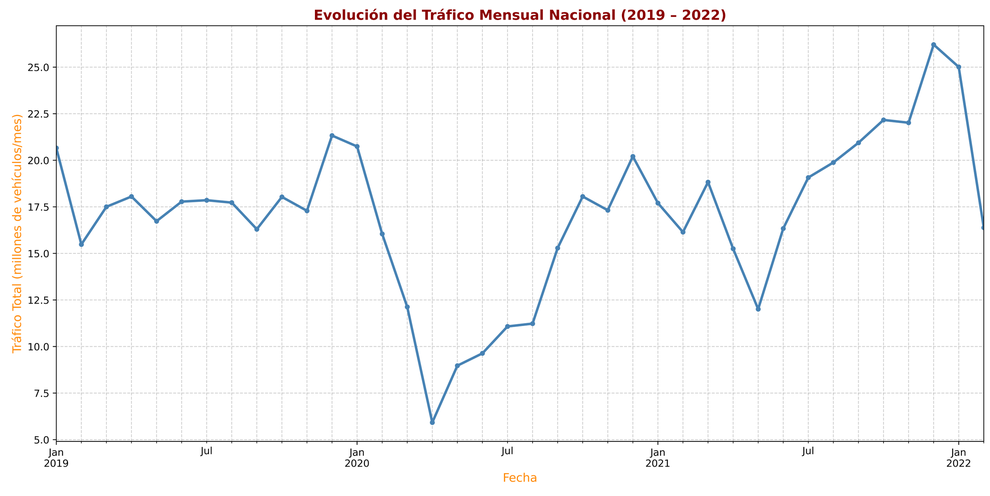


Figura 3:Serie de tiempo del tráfico promedio diario nacional

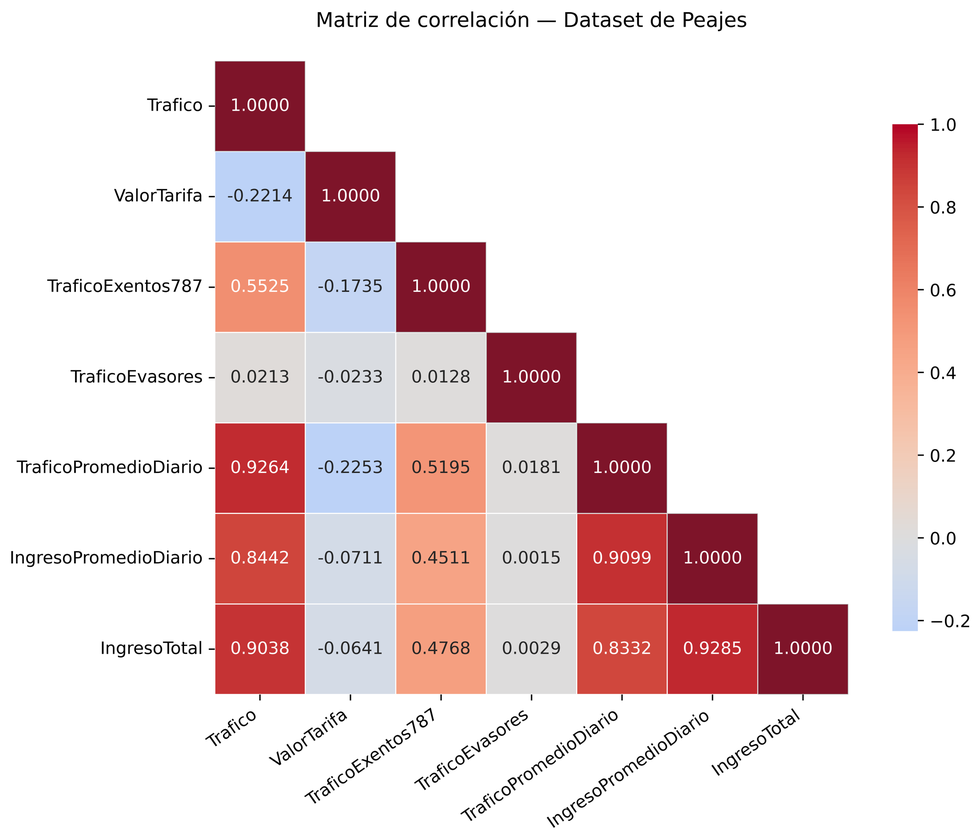


Figura 4:Matriz de correlación entre variables numéricas

Resultados y análisis

Predicción de tráfico promedio diario:

- **Random Forest y XGBoost** alcanzan $R^2 > 0.88$.
- Las **ANN simples** igualan el desempeño o lo superan muy ligeramente con un tuning adecuado.

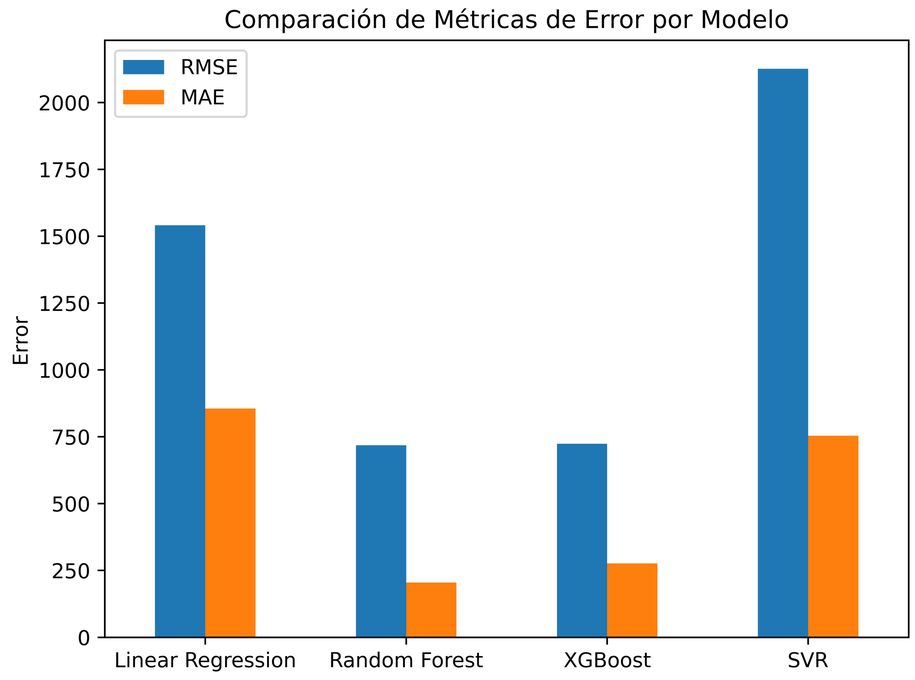


Figura 5:Comparación de desempeño entre modelos (RMSE, MAE, R^2)

Predicción en cascada de ingresos:

- Se usa la predicción de tráfico como entrada adicional.
- **XGBoost** y **Random Forest** mantienen la mejor precisión ($R^2 > 0.80$).
- **ANN mejorada** obtiene $R^2 \approx 0.73$, pero sin superar a los árboles.

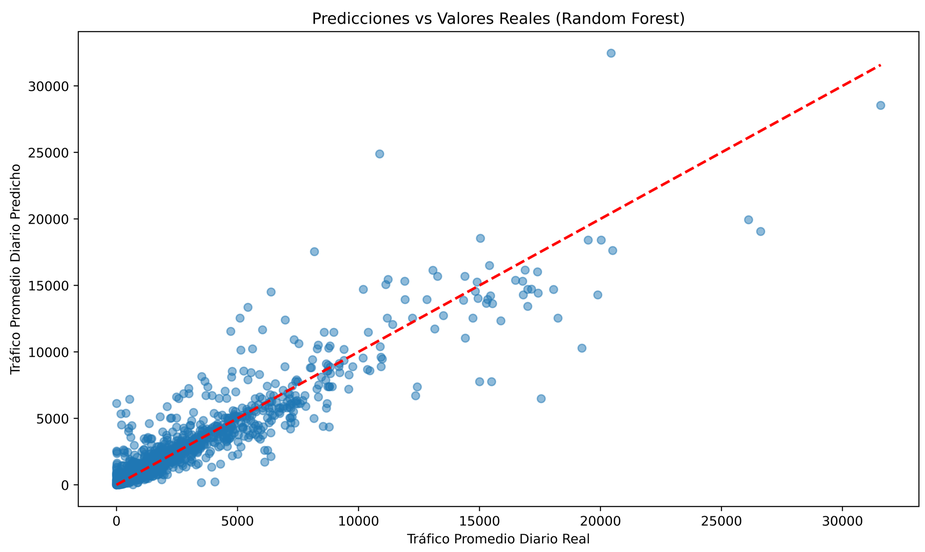


Figura 6:Gráfico de dispersión: valores predichos vs reales para el tráfico

Conclusiones

- Los modelos de aprendizaje supervisado (Random Forest y XGBoost) son los más robustos y eficientes para este tipo de datos tabulares.
- Las redes neuronales pueden competir en la predicción de tráfico, pero no justifican la complejidad adicional.
- El enfoque en cascada refleja mejor la relación entre variables, aunque parece amplificar los errores de la primera etapa.
- El pipeline recomendado es: **Random Forest para tráfico** y **XGBoost para ingresos**.

Referencias

[1] Aurélien Géron. *Hands-on Machine Learning with Scikit-Learn, Keras & TensorFlow*. 3rd Edition. O'Reilly Media, 2023.

[2] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2009.